Podstawy uczenia maszynowego
Część 2

Dr Mateusz Radzimski

Bias & Variance

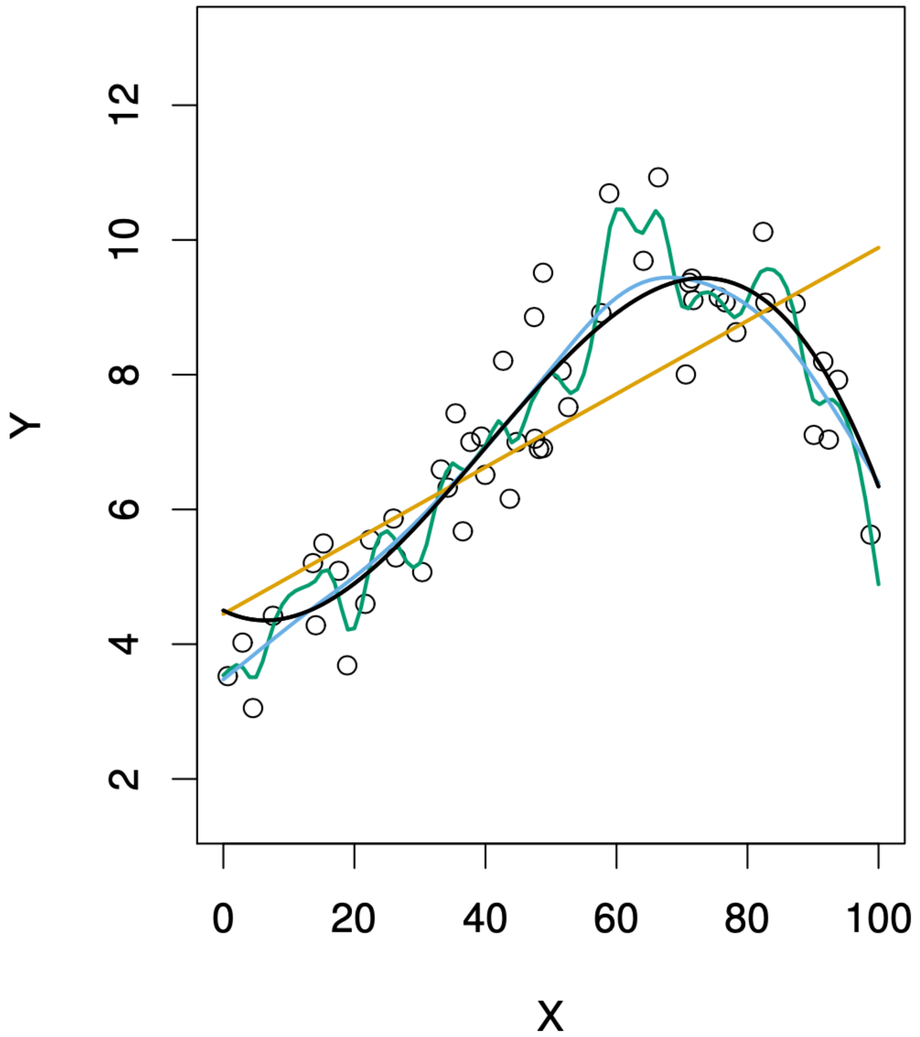

- Terminy te określają jak dobrze dopasowaliśmy model do naszego problemu
- Dla przypomnienia: w regresji liniowej używaliśmy metryki MSE i chcieliśmy aby była najmniejsza
- Można pokazać, że

$$E\left(y_0 - \hat{f}(x_0)\right)^2 = \mathrm{Var}(\hat{f}(x_0)) + [\mathrm{Bias}(\hat{f}(x_0))]^2 + \mathrm{Var}(\epsilon).$$

- Słownie: oczekiwane MSE zbioru testowego = Wariancja + Obciążenie + wariancja błędu nieoznaczonego (nieredukowalnego)

Obciążenie & Wariancja
(Bias & Variance)

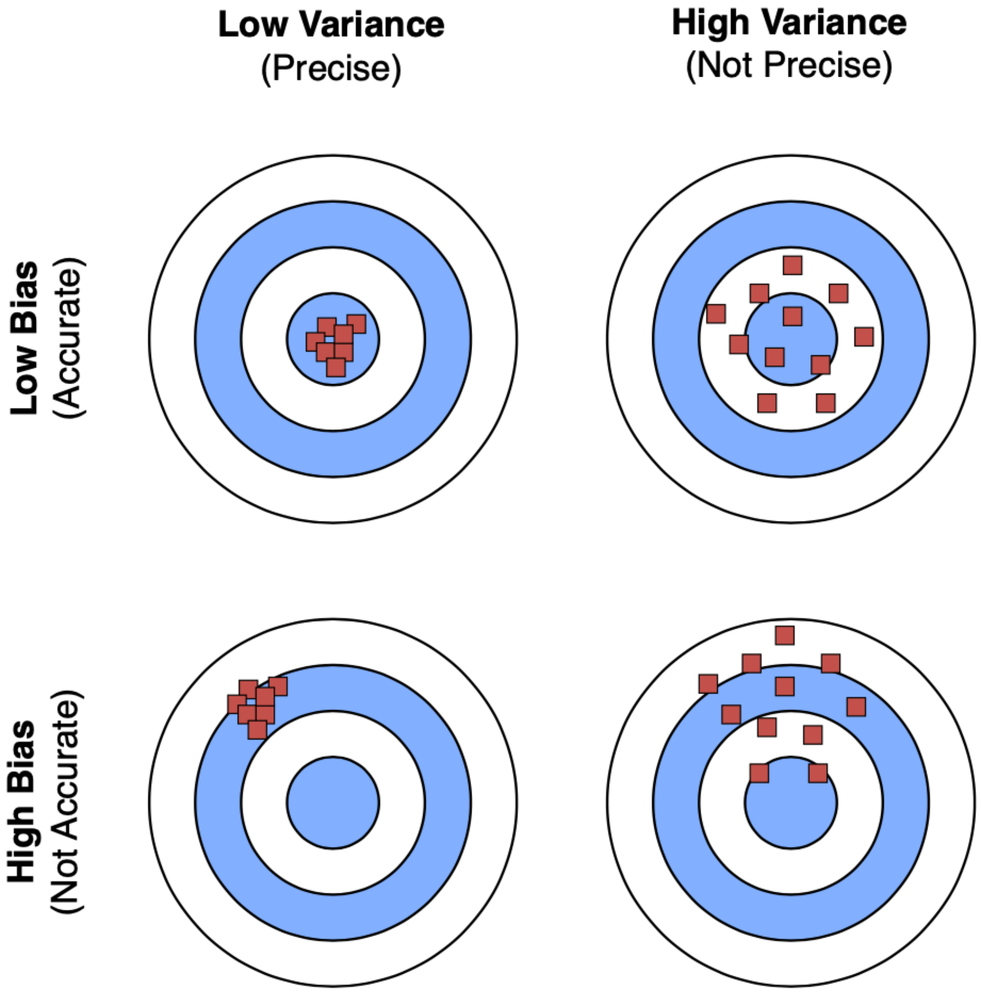

Bias & Variance - intuicja

- Wariancja — Var($\hat{f}$) — jak zmieni się nasza funkcja $\hat{f}$ gdy wyestymujemy ją innymi danymi testowymi
  - W idealnym przypadku inny zbiór obserwacji tego samego zjawiska nie powinien zbytnio wpłynąć na $\hat{f}$
  - Duża wariancja powoduje, że inny zbiór obserwacji spowoduje duże zmiany estymowanej funkcji $\hat{f}$
  - Przebieg zielonej krzywej obrazuje $\hat{f}$ o dużej wariancji
  - Przebieg pomarańczowej prostej za dużo się nie zmieni gdy zmienimy kilka obserwacji - ta funkcja ma małą wariancję
- Błąd wariancji to uczenie się nieistotnych różnic, wrażliwość na lekkie odchylenia

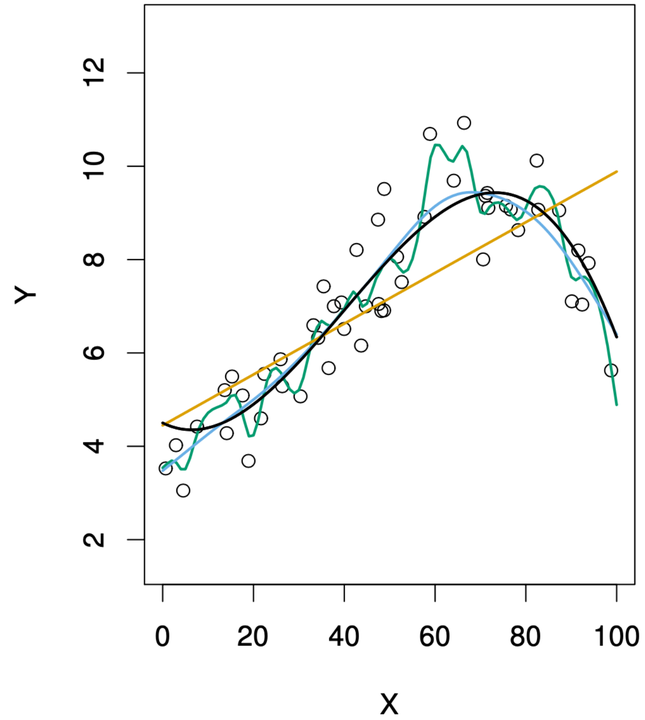

Bias & Variance - intuicja

- Obciążenie — Bias($\hat{f}$) — błąd związany z pewnym przybliżeniem rzeczywistego zjawiska przez uproszczony model
  - Np. regresja liniowa zakłada liniową zależność między Y a $X_1, X_2, X_3 \ldots, X_n$
  - W praktyce wiele zjawisk ma bardziej komplikowane zależności
  - W przykładzie na obrazku regresja liniowa nie jest dobrym dopasowaniem do zbioru uczącego
  - Funkcja $\hat{f}$ reprezentowana przez pomarańczową prostą będzie miała wysokie obciążenie
- Błąd obciążenia to systematyczne uczenie się błędnych rzeczy, wynikające ze złych założeń/złego doboru modelu/itd.

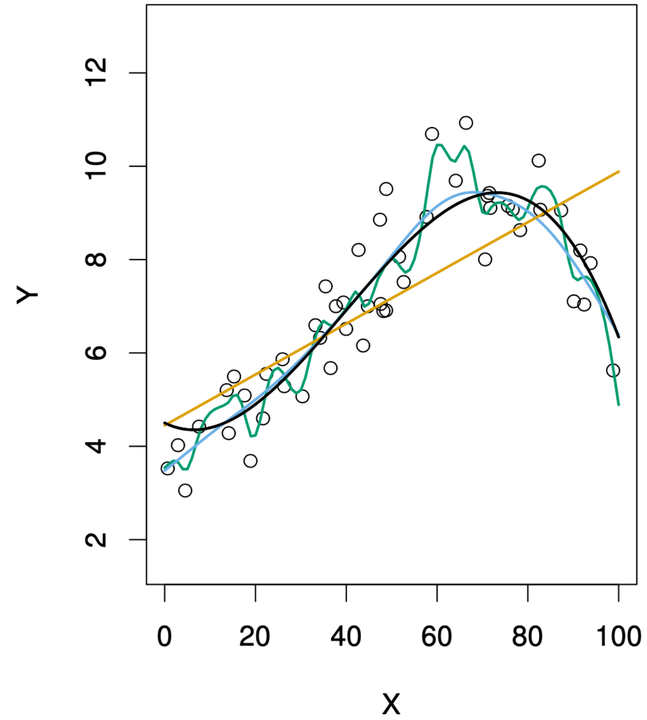

Bias & Variance - kompromis

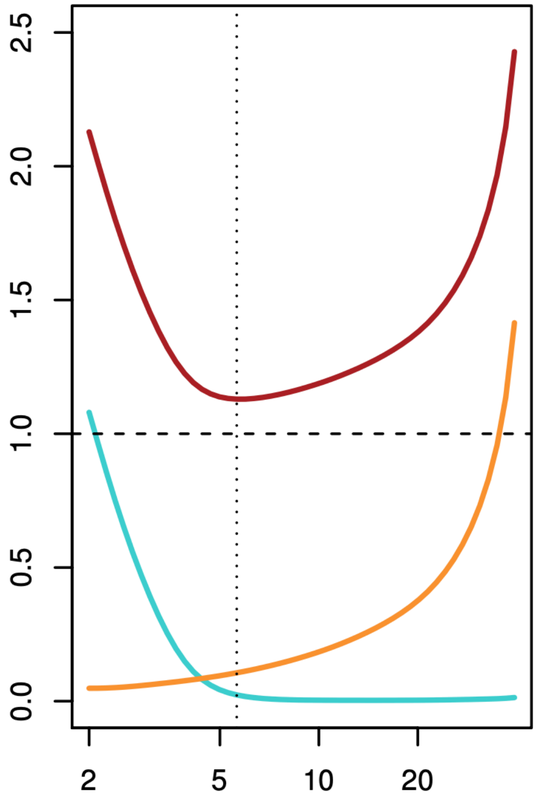

Prostszy model

Zbyt małe dopasowanie (Underfitting)

Bardziej złożony model

Nadmierne dopasowanie (Overfitting)

- Niebieska krzywa - bias
- Pomarańczowa krzywa - wariancja
- Przerywana prosta - błąd nieoznaczony
- Czerwona prosta - oczekiwany MSE dla danych testowych
- Celem jest takie dopasowanie modelu, aby błąd był najmniejszy (minimum czerwonej prostej) - co jest kompromisem między obciążeniem a wariancją.

Underfitting / overfitting

- Kompromis między obciążeniem i wariancją wprost przekłada się na dwa istotne zjawiska:
  - Problem nadmiernego dopasowania / niedotrenowania / underfitting
  - Problem zbyt małego dopasowania / przetrenowania / overfitting

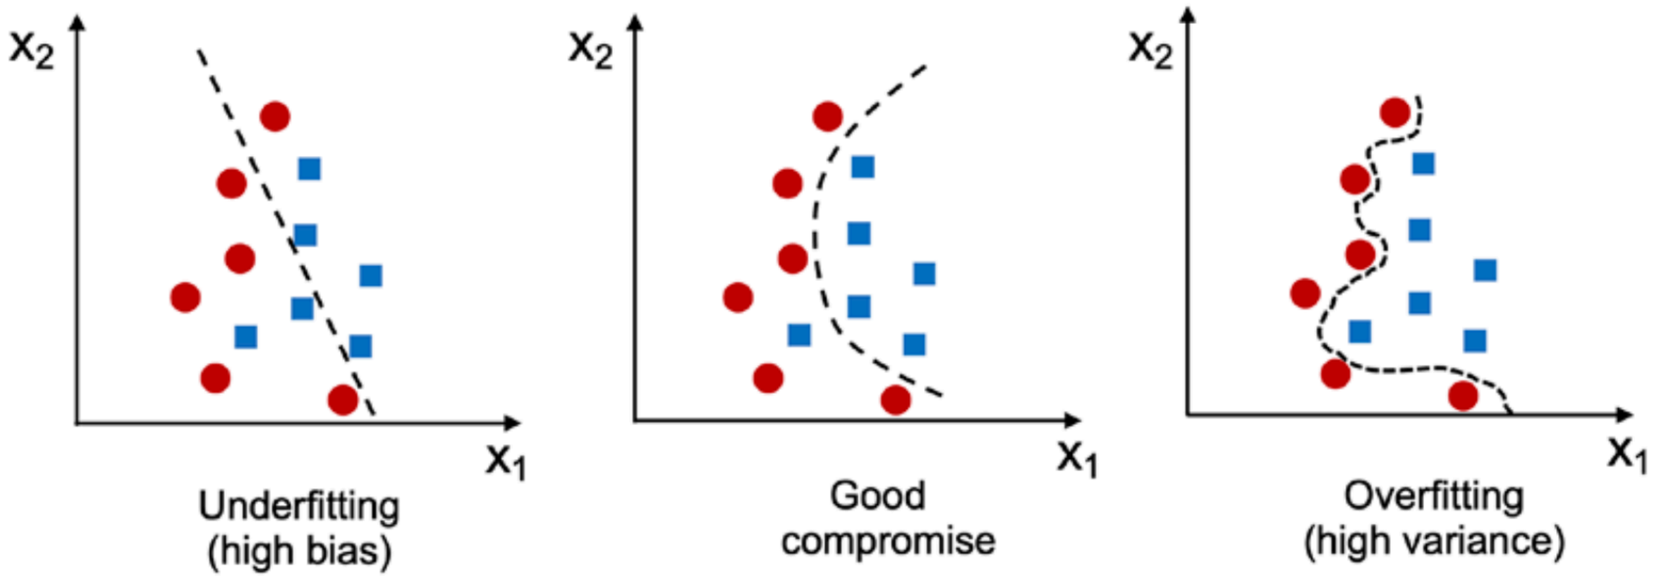

Sposoby na overfitting

- Regularyzacja (o tym w następnym semestrze)
- Uproszczenie modelu
- Przerwanie trenowania zanim algorytm zacznie dopasowywać model do szumu
- Cross validation - nie zapobiegnie, ale pokaże że występuje

Wszystkie te metody będą ważne gdy poznamy nowe algorytmy uczenia maszynowego (szczególnie sieci neuronowe).

Zasady zaliczenia

- Zaliczeniem będzie projekt robiony w grupie 3-4 osobowej (max 5).
- Projekt polega na zastosowaniu regresji liniowej lub klasyfikacji (regresji logistycznej) na wybranym zbiorze danych
  - Zaproponuje 2 zbiory danych do wyboru: jeden na klasyfikacje, drugi na regresje
  - Każdy może tez przyjść ze swoim zbiorem danych (**wtedy zalecam konsultacje ze mną, żeby określić zakres**)
- Rezultatem projektu powinien być notebook (collab), który może zawierać elementy omawiane na wykładzie:
  - Wczytanie danych, może jakaś wizualizacja zbioru
  - Zastosowanie algorytmu uczenia maszynowego
  - Ewaluacja: stworzenie macierzy błędów/metryk modelu/współczynnik R2 regresji itd.
- Zachęcam do wzorowania się na notebookach prezentowanych na wykładzie
- Projekt (notebook) najlepiej wysłać mi mejlem
- Termin do 18 czerwca