

Podstawy Uczenia Maszynowego

Wykład 3

Dr Mateusz Radzinski



**Dlaczego modele się mylą
oraz jak temu zapobiec?**

Po co tworzymy modele?


- Nasz cel: modelowanie rzeczywistości
(model rozumie fundamentalne prawa rządzące zjawiskiem).
- Problem: dane nigdy nie odzwierciedlają rzeczywistości idealnie
(zawsze zawierają szum, anomalie, wyjątki itd).
- **Paradoks:** Aby model zrozumiał ogólny trend, nie powinien uczyć się za dużo. Musi niektóre dane/szum zignorować.

“Psychologia modeli”

Który strzelec jest lepszy?




Obciążenie & Wariancja (Bias & Variance)




Obciążenie (bias) – intuicja

- Obciążenie — $\text{Bias}(\hat{f})$ — błąd związany z pewnym przybliżeniem rzeczywistego zjawiska przez uproszczony model
 - Np. regresja liniowa zakłada liniową zależność między Y a $X_1, X_2, X_3 \dots, X_n$
 - W praktyce wiele zjawisk ma bardziej skomplikowane zależności
 - W przykładzie na obrazku regresja liniowa nie jest dobrym dopasowaniem do zbioru uczącego
 - Funkcja $\hat{f}$ reprezentowana przez pomarańczową prostą będzie miała wysokie obciążenie
- Błąd obciążenia to systematyczne uczenie się błędnych rzeczy, wynikające ze złych założeń/złego doboru modelu/itd.




Wariancja (variance) — intuicja

- Wariancja — $\text{Var}(\hat{f})$ — jak zmieni się nasza funkcja $\hat{f}$ gdy wyestymujemy ją innymi danymi treningowymi?
 - W idealnym przypadku inny zbiór obserwacji tego samego zjawiska nie powinien zbyt wiele wpłynąć na $\hat{f}$
 - Duża wariancja powoduje, że inny zbiór obserwacji spowoduje duże zmiany estymowanej funkcji $\hat{f}$
 - Przebieg zielonej krzywej obrazuje $\hat{f}$ o dużej wariancji
 - Przebieg pomarańczowej prostej za dużo się nie zmieni gdy zmienimy kilka obserwacji - ta funkcja ma małą wariancję
- Błąd wariancji to uczenie się nieistotnych różnic, wrażliwość na lekkie odchylenia



Bias & Variance




- Spojrzenie bardziej matematyczne
- Dla przypomnienia: w regresji liniowej używaliśmy metryki MSE i chcieliśmy aby była najmniejsza
- Cały ten wykład zawiera się w jednym równaniu:

$$E \left(y_0 - \hat{f}(x_0) \right)^2 = \text{Var}(\hat{f}(x_0)) + [\text{Bias}(\hat{f}(x_0))]^2 + \text{Var}(\epsilon).$$

- Słownie: Oczekiwany błąd modelu zawsze będzie się składał z wariancji, obciążenia i wariancji szumu (błędu nieredukowalnego)

Bias & Variance — intuicja



← Prostszy model
Zbyt małe dopasowanie
(Underfitting)

→ Bardziej złożony model
Nadmierne dopasowanie
(Overfitting)

- Niebieska krzywa - bias
- Pomarańczowa krzywa - wariancja
- Przerywana krzywa - błąd nieoznaczony
- Czerwona krzywa - oczekiwany MSE dla danych testowych
- Celem jest takie dopasowanie modelu, aby błąd był najmniejszy (minimum czerwonej prostej) - co jest kompromisem między obciążeniem a wariancją.

Underfitting / overfitting


- Kompromis między obciążeniem i wariancją wprost przekłada się na dwa istotne zjawiska:
 - Problem zbyt małego dopasowania / niedotrenowania / **underfitting**
 - Problem nadmiernego dopasowania / przetrenowania / **overfitting**

Underfitting / overfitting

- Zobaczymy jak problem underfittingu / overfittingu wygląda w przypadku algorytmów klasyfikacji
- Przykład: klasyfikacja owoców
 - Zbyt prosty model (np. klasyfikuje owoce po kolorze) — underfitting
 - Zbyt skomplikowany model (np. klasyfikuje owoc jako jabłko bo był koszyku albo w tle jest drzewo, i dodatkowo ma drobne brązowe plamki) — overfitting

Underfitting / overfitting

- Ten sam przykład, ale pokazany przy pomocy regionów decyzyjnych.
- Cel to stworzenie modelu który zapewni dobry kompromis między niedotrenowaniem a przetrenowaniem.



Notatnik:

04 - Bias and Variance.ipynb

Sposoby na overfitting

- **Dostarczenie większej ilości danych uczących**
- Regularyzacja (o tym w następnym semestrze)
- Uproszczenie modelu
- Przerwanie trenowania zanim algorytm zacznie dopasowywać model do szumu
- Cross validation - pozwala wykryć overfitting i wybrać wystarczająco złożony model

Wszystkie te metody bardzo się przydadzą się, gdy poznamy kolejne algorytmy uczenia maszynowego (np. sieci neuronowe).