

Podstawy uczenia maszynowego

Część 4

Dr Mateusz Radzimski

Regresja wielowymiarowa

(Multivariate linear regression)

Przypomnienie dotyczących czasowych metod

Sytuacja

Obserwacje z etykietami (klasami)
Cel: przewidywanie etykiet (klas)

Wejście: Dane z wartościami liczbowymi
Cel: przewidywanie wartości ciągłych

Klasyfikacja

Regresja

Regresja Logistyczna




Regresja Liniowa

Tabular data

Features & Label Samples	F1	F2	F3	F4	Label
Sample_1	$v_{1,1}$	$v_{1,2}$	$v_{1,3}$	$v_{1,4}$	L_1
Sample_2	$v_{2,1}$	$v_{2,2}$	$v_{2,3}$	$v_{2,4}$	L_2
Sample_3	$v_{3,1}$	$v_{3,2}$	$v_{3,3}$	$v_{3,4}$	L_3
.	.	.	.	.	.
.	.	.	.	.	.
.	.	.	.	.	.
Sample_n	$v_{n,1}$	$v_{n,2}$	$v_{n,3}$	$v_{n,4}$	L_n

Homework Grade (x)	Test Grade (y)
94	98
95	94
92	95
87	89
82	85
80	78
75	73
65	67
50	45
20	40

Przypomnienie dotychczasowych metod



	TV	Radio	Newspaper	Sales
0	230.1	37.8	69.2	22.1
1	44.5	39.3	45.1	10.4
2	17.2	45.9	69.3	12.0
3	151.5	41.3	58.5	16.5
4	180.8	10.8	58.4	17.9
...	...	...	...	...
195	38.2	3.7	13.8	7.6
196	94.2	4.9	8.1	14.0
197	177.0	9.3	6.4	14.8
198	283.6	42.0	66.2	25.5
199	232.1	8.6	8.7	18.4

200 rows x 4 columns

W przykładzie ze zbiorem danych „Advertisment” tworzyliśmy model regresji liniowej na podstawie jednej zmiennej niezależnej: np. $\text{Sales} \sim \text{TV}$.


Jest to tzw. prosta regresja liniowa (simple linear regression).

Co zrobić w przypadku gdy mamy więcej zmiennych niezależnych?

Regresja wielowymiarowa

- Regresję możemy stosować również w przypadku, gdy mamy do czynienia z wieloma zmiennymi niezależnymi

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	Price
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.0900	1.0	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.9671	2.0	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.9671	2.0	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.0622	3.0	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.0622	3.0	222.0	18.7	396.90	5.33	36.2



Regresja wielowymiarowa - model

- Model wielowymiarowej regresji liniowej przyjmuje postać:

$$Y = f(X) + \epsilon$$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \epsilon$$


- Parametry $\beta_1 \dots \beta_p$ określają w jaki sposób zmienne niezależne X_j wpływają na zmienną zależną Y .
- ϵ to tzw. błąd nieusuwalny, wynikający z naturalnego “szumu” obecnego w danych
- Wracając do przykładu ze zbioru danych „Advertising”:

$$\text{Sales} = \beta_0 + \beta_1 \cdot \text{TV} + \beta_2 \cdot \text{Radio} + \beta_3 \cdot \text{Newspaper} + \epsilon$$

Regresja wielowymiarowa – estymacja parametrów

- Podobnie jak w przypadku regresji prostej, używamy metody najmniejszych kwadratów.
- Suma kwadratów odległości naszych obserwacji od *płaszczyzny* (hyperplane) definiującą naszą regresję.

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_p x_{ip})^2$$



Ewaluacja parametrów

- Podobnie jak w przypadku regresji prostej, chcemy odpowiedzieć na pytanie: czy jest (istotna statystycznie) zależność między zmiennymi niezależnymi a zmienną zależną
 - Hipoteza zerowa: $H_0: \beta_1 = \beta_2 = \dots = \beta_p = 0$
 - Hipoteza alternatywna: H_1 : conajmniej jeden parametr β_j jest różny od zera
- Wciąż moglibyśmy użyć p-value pojedynczych parametrów, tak jak w przypadku regresji prostej, jednakże może być to problematyczne dla dużej ilości zmiennych
- Do odrzucenia hipotezy zerowej używamy więc testu F, a w szczególności statystyki F (F-statistics)
 - Test F bada *łącną* istotność parametrów dla całego modelu
 - Wartość *F-statistics* powinna być dużo większa od 1



Polecam zainteresowanym

Ewaluacja parametrów

```
X_train = df[["TV", "Radio", "Newspaper"]]  
y_train = df["Sales"]
```

```
X2 = sm.add_constant(X_train)  
est = sm.OLS(y_train, X2)  
regression_model = est.fit()  
print(regression_model.summary())
```

OLS Regression Results

Dep. Variable:	Sales	R-squared:	0.903
Model:	OLS	Adj. R-squared:	0.901
Method:	Least Squares	F-statistic:	605.4
Date:	Fri, 12 May 2023	Prob (F-statistic):	8.13e-99
Time:	21:25:35	Log-Likelihood:	-383.34
No. Observations:	200	AIC:	774.7
Df Residuals:	196	BIC:	787.9
Df Model:	3		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	4.6251	0.308	15.041	0.000	4.019	5.232
TV	0.0544	0.001	39.592	0.000	0.052	0.057
Radio	0.1070	0.008	12.604	0.000	0.090	0.124
Newspaper	0.0003	0.006	0.058	0.954	-0.011	0.012

Omnibus:	16.081	Durbin-Watson:	2.251
Prob(Omnibus):	0.000	Jarque-Bera (JB):	27.655
Skew:	-0.431	Prob(JB):	9.88e-07
Kurtosis:	4.605	Cond. No.	454.

Współczynniki β

R^2

Wartość statystyki F

P-value dla hipotezy H_0
(Niska wartość $\rightarrow$ odrzucamy H_0)

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.


04 - Intro to multivariate regression

Wybór zmiennych

- Na poprzednim przykładzie widzieliśmy, że nie zawsze warto „wrzucać” wszystkie zmienne do regresji liniowej
- Strategie wyboru zmiennych:
 - *Forward selection* - najpierw robimy p prostych regresji, patrzymy która zmienna ma największy współczynnik R^2 (lub najmniejszy RSS) i wybieramy ją do modelu, kontynuujemy aż do ustalonego momentu
 - *Backward selection* - budujemy model regresji liniowej ze wszystkich zmiennych, a następnie usuwamy zmienną o największym parametrze p-value, kontynuujemy aż do ustalonego momentu (np. Wszystkie zmienne mają p-value poniżej ustalonego progu)
 - *Mixed selection* - kombinacja powyższych: zaczynamy tak jak przy strategii *forward selection*, ale gdy dla którejkolwiek zmiennej parametr p-value wzrośnie powyżej pewnej wartości, wtedy taką zmienną usuwamy.

Efekt „synergii”

- Regresja liniowa zakłada, że zależność między zmiennymi niezależnymi a zmienną zależną jest liniowa i *addytywna*, tj. Zależność między $Y \sim X_j$ nie zależy od innych zmiennych.
- W przypadku zbioru „advertising” nasza regresja niedoszacowuje sytuacji, w których wydajemy budżet na dwa kanały: radio i telewizję.
- Pojawia się nieliniowość sugerująca pewien rodzaj synergii lub interakcji między obiema kanałami reklamy, skutkującym większą sprzedażą niż gdyby użyć tych kanałów oddzielnie.



Efekt „synergii”

- Można taką sytuację zapisać:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1 X_2 + \epsilon$$

- Albo:

$$\text{Sales} = \beta_0 + \beta_1 \cdot \text{TV} + \beta_2 \cdot \text{Radio} + \beta_3 \cdot \text{TV} \cdot \text{Radio} + \epsilon$$



- Taki model znów staje się liniowy

Notatnik:

05 - Intro to multivariate regression



Kiedy stosować regresję liniową

- Zależność między zmiennymi niezależnymi a zmienną zależną jest liniowa
- Eksploracja danych: wykresy punktowe (scatterplot)



Kiedy stosować regresję liniową

- Regresja liniowa jest mało odporna na dane odstające (outliers)
- Rozważyć odrzucenie outlierów



Kiedy stosować regresję liniową

- Zmienne niezależne nie są skorelowane ze sobą
 - Odrzucić „nadmiarowe” zmienne które są wysoko skorelowane („multicollinearity”)
 - Metoda VIF („Variance Inflation Factor”)
- Jednorodność wariancji, homoskedastyczność (homoscedasticity) - błędy wartości przewidywanej są w miarę stałe i np. nie rosną wraz ze wzrostem wartości przewidywanej

Variance Inflation Factor (VIF)

- Identyfikacja korelacji zmiennych niezależnych
- Szukamy współczynnika R^2 dla regresji pomiędzy każdą zmienną niezależną vs. wszystkie pozostałe zmienne
- $VIF = 1$ - brak korelacji, $VIF > 5$ - korelacja którą warto wyeliminować.

- $$VIF = \frac{1}{1 - R^2}$$

```
from statsmodels.stats.outliers_influence import variance_inflation_factor

vif_results = pd.DataFrame()
vif_results["feature"] = X.columns

vif_results["VIF"] = [variance_inflation_factor(X.values, i) for i in range(len(X.columns))]
```


Follow up

- Nie damy rady omówić wszystkich matematycznych i technicznych aspektów regresji
- Dla zainteresowanych polecam zgłębić problemy:
 - Regularyzacji (regularisation)
 - Metoda gradientu prostego (gradient descent) w znajdowaniu minimum funkcji celu
 - Jak w praktyce wygląda trenowanie regresji liniowej
- Materiały:
 - Andrew Ng videos on YouTube: „Lecture 4.2 — Linear Regression With Multiple Variables”
 - Książka: „The Elements of Statistical Learning” Jerome H. Friedman, Robert Tibshirani i Trevor Hastie

Rodzaje danych wejściowych

Rzut oka na przykłady

- Titanic dataset

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...)	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

Rodzaje danych wejściowych

- Wartości liczbowe
- Wartości skategoryzowane
- Wartości tekstowe (strings)
- Daty
- Dźwięk
- Obrazy
- ...

Wartości skategoryzowane

- Zamiana na tzw. „Dummy variables” albo „1 z n” (one hot encoding)
- Przykład

	Person	Education	Salary(annum)
0	amit	Under-Graduate	\$90k
1	vishal	Diploma	\$80k
2	john	Under-Graduate	\$90k
3	marry	Diploma	\$60k
4	sherin	Under-Graduate	\$90k
5	komal	Under-Graduate	\$100k
6	jay	Under-Graduate	\$60k
7	shree	Under-Graduate	\$100k
8	kishore	Diploma	\$90k
9	geetha	Diploma	\$70k
10	savitha	Under-Graduate	\$50k
11	vinith	Under-Graduate	\$90k



	Diploma	Master's	Under-Graduate
0	0	0	1
1	1	0	0
2	0	1	0
3	0	1	0
4	0	0	1
5	1	0	0
6	0	0	1
7	0	0	1
8	0	0	1
9	0	0	1
10	1	0	0
11	1	0	0
12	0	0	1
13	0	0	1

Brakujące dane

Przykłady

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...)	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S
3	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.0	1	0	113803	53.1000	C123	S
4	5	0	3	Allen, Mr. William Henry	male	35.0	0	0	373450	8.0500	NaN	S

NaN - Not a Number

NA - Not Available

„” - puste pole

Reprezentacja brakujących danych

- Strategie traktowania brakujących danych:
 - Usunięcie (wiersza - danej obserwacji, kolumny - odrzucenie zmiennej niezależnej)
- Uzupełnienie danych
 - Wartości liczbowe: interpolacją wartości, średnia, taka sama jak poprzednia, inne bardziej zaawansowane metody
 - Wartości skategoryzowane: dodanie nowej klasy

05 - Handling data