

Podstawy Uczenia Maszynowego

Projekt grupowy

Zasady

- Projekt grupowy pozwala dostać lepszą ocenę
- Projekt możemy robić w grupach 3-4 osobowych (max 5 osób). Można też zrobić indywidualnie.
- Projekt polega na zastosowaniu regresji liniowej lub klasyfikacji (regresji logistycznej) na wybranym zbiorze danych
 - Zaproponuje kilka popularnych zbiorów danych, z których można sobie wybrać dowolny.
 - Każdy może też przyjść ze swoim zbiorem danych (**wtedy zalecam konsultacje ze mną, żeby określić zakres pracy oraz ewentualne wskazówki**)
- Rezultatem projektu powinien być notatnik (collab notebook, w formacie *.ipynb), który może zawierać elementy omawiane na wykładach:
 - „Checklista” na następnym slajdzie
- Zachęcam do wzorowania się na notebookach prezentowanych na wykładzie
- Projekt (notebook) najlepiej wysłać mi mejlem
- Termin do 15 lipca 2026. Jeśli ktoś planuje urlop i nie zdąży to proszę o informację.

Checklista projektu (notatnika)

- Wczytanie danych
- Prosta wizualizacja danych (i/lub inne statystyki zbioru)
- Opcjonalnie: Obsługa brakujących danych / inżynieria cech
- Opcjonalnie: Podział na zbiór uczący / trenujący (w przypadku klasyfikacji)
- Zastosowanie algorytmu uczenia maszynowego
- Ewaluacja wyniku: stworzenie macierzy błędów/metryk modelu/współczynnik R^2 regresji (w zależności od użytego modelu)
- Komentarze do kodu

Przykładowe zbiory danych

- Titanic dataset (klasyfikacja)
<https://github.com/mateuszr/ml-course-1/blob/main/datasets/titanic-full.csv>
- Penguins (klasyfikacja)
<https://github.com/mateuszr/ml-course-1/blob/main/datasets/penguins.csv>
- California housing dataset (regresja)
<https://github.com/mateuszr/ml-course-1/blob/main/datasets/housing.csv>
- Ames housing dataset (regresja)
<https://github.com/mateuszr/ml-course-1/blob/main/datasets/AmesHousing.csv>
- Cars (regresja)
<https://github.com/mateuszr/ml-course-1/blob/main/datasets/cars.csv>
- Credit (klasyfikacja lub regresja)
<https://github.com/mateuszr/ml-course-1/blob/main/datasets/credit.csv>


Titanic



- Zbiór danych zawiera 12 kolumn i 1309 wierszy. Znaczenie kolumn:
 - **survival: przeżycie** 0 = Nie, 1 = Tak
 - pclass: rodzaj biletu 1 = 1 Klasa, 2 = 2 Klasa, 3 = 3 Klasa
 - sex: płeć
 - age: wiek w latach
 - sibsp: ilość rodzeństwa (+ żona) na pokładzie
 - parch: ilość rodziców / dzieci na pokładzie
 - ticket: numer biletu
 - fare: opłata
 - cabin: numer kabiny
 - embarked: port zaokrętowania (wejścia na pokład) C = Cherbourg, Q = Queenstown, S = Southampton
- Przykład zadania: predykcja przeżycia

Penguins

- Zbiór danych zawiera 7 kolumn
 - **species:** gatunek (Chinstrap, Adélie, or Gentoo)
 - **culmen_length_mm:** długość dzioba
 - **culmen_depth_mm:** wysokość dzioba
 - **flipper_length_mm:** długość skrzydła
 - **body_mass_g:** masa ciała
 - **island:** nazwa wyspy z Archipelagu Palmera (Antarktyda)
 - **sex:** płeć
- Przykład zadania: klasyfikacja gatunku na podstawie cech anatomii



CULMEN: RIDGE ALONG THE
TOP PART OF A BIRD'S BILL



California Housing Dataset

- Nowoczesna alternatywa dla zbioru Boston Housing. Przewidywanie mediany wartości domów w dystryktach Kalifornii (dane ze spisu powszechnego)
- Cechy: longitude, latitude, housing_median_age, total_rooms, total_bedrooms, population, households, median_income, median_house_value, ocean_proximity
- Regresja liniowa, poziom trudności: łatwy

Ames Housing Dataset

- Rozbudowany zbiór danych o nieruchomościach. Aż 79 zmiennych (kategorycznych i liczbowych) określających każdy aspekt domu w Ames, Iowa.
- Regresja liniowa.
- Trudniejszy zbiór, brakujące dane, zmienne tekstowe

Cars

- Zbiór danych z 392 obserwacjami i 9 zmiennymi:
 - mpg - miles per gallon - zużycie paliwa (w milach na galon paliwa)
 - cylinders - liczba cylindrów (od 4 do 8)
 - displacement - objętość skokowa (cale sześciennie)
 - horsepower - moc (konie mechaniczne)
 - weight - waga (w funtach)
 - acceleration - przyspieszenie w sekundach do 60 mil na godzinę
 - year - rok produkcji (z ostatnie cyfry roku, XX wiek)
 - origin - kraj produkcji (1. American, 2. European, 3. Japanese)
 - name - nazwa samochodu
- Przykład zadania: od czego zależy bardziej ekonomiczne zużycie paliwa?

Credit

- Zbiór danych 400 fikcyjnych klientów banku:
 - Income - dochody (w tys \$)
 - Limit - limit kredytowy
 - Rating - rating
 - Cards - liczba kart kredytowych
 - Age - wiek (w latach)
 - Education - edukacja (w latach)
 - Own - czy jest właścicielem mieszkania/domu
 - Student - czy jest studentem
 - Married - czy jest żonaty/ma męża
 - Region - region (East, South, and West)
 - **Balance - dług w \$**
- Przykładowe zadanie: jak przewidzieć wysokość długu? Od czego on zależy?